

Tổng quan bài toán Text To Speech (TTS)

1. Giới thiệu chung về bài toán TTS

Text To Speech (TTS) là bài toán chuyển đổi văn bản (text) thành tín hiệu âm thanh (speech) sao cho:

- Phát âm **đúng**
- Ngữ điệu **tự nhiên**
- Có thể kiểm soát **giọng nói, cảm xúc, ngôn ngữ**

TTS là thành phần cốt lõi trong nhiều hệ thống hiện đại:

- Trợ lý ảo (Google Assistant, Siri, Alexa)
- Hệ thống đọc sách, hỗ trợ người khiếm thị
- Chatbot đa phương thức
- Game, phim, dubbing, AI agent

Lịch sử phát triển của TTS có thể chia thành **3 level chính**, tương ứng với mức độ phức tạp, tính tự nhiên và yêu cầu tài nguyên.

2. Bức tranh toàn cảnh về bài toán Text To Speech

Bài toán Text To Speech (TTS) đã trải qua nhiều giai đoạn phát triển, có thể được phân chia một cách tổng quát thành **ba level tiếp cận chính**, tương ứng với sự tiến bộ của công nghệ và yêu cầu ngày càng cao về chất lượng giọng nói tổng hợp.

2.1 Level 1 – Hệ thống TTS dựa trên luật

Level 1 đại diện cho giai đoạn khởi đầu của bài toán TTS, trong đó các hệ thống chủ yếu dựa trên **các luật ngữ âm và âm tiết cơ bản**. Văn bản đầu vào được phân tích theo những quy tắc ngôn ngữ định sẵn, sau đó chuyển đổi thành các đơn vị âm thanh để tạo ra giọng nói.

Hướng tiếp cận này có các đặc điểm nổi bật như:

- Tốc độ xử lý nhanh,
- Yêu cầu rất ít tài nguyên tính toán,
- Dễ áp dụng cho nhiều ngôn ngữ khác nhau nhờ việc xây dựng bộ luật riêng cho từng ngôn ngữ.

Tuy nhiên, nhược điểm lớn của Level 1 là **giọng nói tổng hợp thiếu tính tự nhiên**, ngữ điệu cứng nhắc và gần như không thể biểu đạt cảm xúc.

2.2 Level 2 – TTS dựa trên Deep Learning

Với sự phát triển của các mô hình **Deep Learning**, bài toán TTS bước sang một giai đoạn mới, trong đó chất lượng giọng nói được cải thiện rõ rệt. Các mô hình học sâu có khả năng học trực tiếp mối quan hệ giữa văn bản và đặc trưng âm thanh, từ đó tạo ra giọng nói tự nhiên hơn so với các hệ thống dựa trên luật.

Tuy nhiên, một thách thức lớn của Level 2 là việc **đảm bảo tính đa ngôn ngữ**, do các mô hình này thường yêu cầu lượng dữ liệu huấn luyện đáng kể cho từng ngôn ngữ và từng giọng nói.

Để khắc phục hạn chế này, nhiều nghiên cứu đã đề xuất xây dựng **pipeline toàn diện cho từng người dùng**, trong đó:

- Mỗi người dùng tự ghi âm dữ liệu giọng nói của mình,
- Mô hình TTS được tinh chỉnh (fine-tune) với **trọng số riêng cho từng người**.

Cách tiếp cận này giúp mô hình:

- Đạt được giọng nói tự nhiên cao,
- Tiêu tốn ít tài nguyên hơn so với các mô hình phức tạp ở Level 3,
- Phù hợp với các ứng dụng cá nhân hóa giọng nói.

2.3 Level 3 – Few-shot / Zero-shot TTS

Level 3 là hướng tiếp cận hiện đại nhất trong nghiên cứu TTS hiện nay. Thay vì yêu cầu nhiều dữ liệu huấn luyện cho mỗi người nói, các mô hình ở level này chỉ cần **vài giây âm thanh mẫu** để trích xuất đặc trưng giọng nói, từ đó tổng hợp giọng nói mới mang đặc trưng của người nói cho trước.

Ưu điểm của Level 3 là:

- Giảm đáng kể công sức chuẩn bị dữ liệu của người dùng,
- Dễ mở rộng cho nhiều giọng nói khác nhau,
- Tiềm năng cao trong các hệ thống đa ngôn ngữ và đa người dùng.

Tuy nhiên, các mô hình few-shot thường có:

- Kiến trúc phức tạp,
- Yêu cầu tài nguyên tính toán lớn,
- Chi phí triển khai cao hơn so với Level 1 và Level 2.

2.4 Nhận xét chung và các thách thức nghiên cứu

Cả ba hướng tiếp cận trong bài toán TTS đều tồn tại **ưu và nhược điểm riêng**, và việc lựa chọn phương pháp phù hợp phụ thuộc vào nhu cầu sử dụng cũng như nguồn lực tính toán sẵn có.

Các nghiên cứu hiện nay trong lĩnh vực TTS tập trung giải quyết những thách thức chung sau:

- Đạt hiệu suất xử lý nhanh (tương tự Level 1),
- Giảm chi phí và tài nguyên tính toán,
- Đảm bảo tính tự nhiên của giọng nói (như Level 2 và Level 3),
- Hỗ trợ đa ngôn ngữ,
- Bổ sung khả năng biểu đạt cảm xúc cho giọng nói tổng hợp,
- Giảm tối đa công sức của người dùng (ví dụ: không cần dữ liệu hoặc chỉ cần vài giây ghi âm).

2.5 Vấn đề đạo đức trong nghiên cứu TTS

Song song với sự phát triển của công nghệ, các vấn đề đạo đức cũng ngày càng được quan tâm. Một trong những hướng nghiên cứu quan trọng hiện nay là **nhúng watermark vào âm thanh do mô hình AI tạo ra**, nhằm đánh dấu và phân biệt với giọng nói thật, từ đó giảm thiểu nguy cơ **deepfake** và lan truyền thông tin sai lệch.

3. Phân tích ưu/nhược điểm và các pipeline nghiên cứu trong TTS

3.1. Phân tích ưu và nhược điểm của các hướng tiếp cận

Level 1 – Hệ thống TTS dựa trên luật

Ưu điểm

- Hiệu suất xử lý rất nhanh, độ trễ thấp.
- Yêu cầu tài nguyên tính toán tối thiểu.
- Dễ mở rộng sang nhiều ngôn ngữ thông qua việc xây dựng bộ luật ngữ âm.

- Phù hợp với các hệ thống nhúng hoặc thiết bị có cấu hình thấp.

Nhược điểm

- Giọng nói tổng hợp thiếu tính tự nhiên.
- Ngữ điệu đơn điệu, khó thể hiện ngữ cảnh và cảm xúc.
- Khó cải thiện chất lượng nếu không thiết kế lại toàn bộ bộ luật.

Nhận xét

Level 1 phù hợp cho các ứng dụng ưu tiên hiệu suất và tính đơn giản, nhưng không đáp ứng được yêu cầu về chất lượng giọng nói trong các hệ thống hiện đại.

Level 2 – TTS dựa trên Deep Learning

Ưu điểm

- Chất lượng giọng nói tự nhiên, gần với giọng người thật.
- Có thể kiểm soát một số yếu tố như tốc độ, cao độ, ngữ điệu.
- Sau khi tinh chỉnh cho từng người dùng, mô hình có thể chạy với tài nguyên tương đối thấp.

Nhược điểm

- Phụ thuộc nhiều vào dữ liệu huấn luyện.
- Khó mở rộng sang nhiều ngôn ngữ hoặc nhiều người nói nếu không có dữ liệu tương ứng.
- Công sức chuẩn bị dữ liệu ban đầu tương đối lớn.

Nhận xét

Level 2 là lựa chọn cân bằng giữa chất lượng và chi phí, phù hợp với các hệ thống cá nhân hóa giọng nói nhưng vẫn bị giới hạn bởi dữ liệu.

Level 3 – Few-shot / Zero-shot TTS

Ưu điểm

- Chỉ cần rất ít dữ liệu (vài giây âm thanh) để tạo giọng nói mới.
- Dễ mở rộng cho nhiều người dùng khác nhau.
- Tiềm năng cao trong các hệ thống đa ngôn ngữ và đa giọng nói.

Nhược điểm

- Kiến trúc mô hình phức tạp.
- Yêu cầu tài nguyên tính toán lớn.
- Chi phí triển khai và vận hành cao.
- Nguy cơ bị lạm dụng cho mục đích giả mạo giọng nói.

Nhận xét

Level 3 mang lại tính linh hoạt cao nhất nhưng đi kèm với chi phí lớn và các vấn đề đạo đức cần được kiểm soát chặt chẽ.

3.2. Các pipeline nghiên cứu nhằm tối ưu ưu điểm và giảm nhược điểm

3.2.1. Pipeline tối ưu hiệu suất và tài nguyên

Để giải quyết vấn đề tốc độ và chi phí tính toán, nhiều nghiên cứu tập trung vào:

- Sử dụng mô hình **non-autoregressive** nhằm giảm độ trễ khi sinh âm thanh.
- Áp dụng các kỹ thuật **model compression, quantization** và **knowledge distillation**.
- Thiết kế vocoder nhẹ nhưng vẫn đảm bảo chất lượng âm thanh.

Pipeline tổng quát:

Text → Text Encoder → Acoustic Model (nhẹ) → Vocoder tối ưu → Audio

3.2.2. Pipeline đảm bảo tính đa ngôn ngữ

Các nghiên cứu đa ngôn ngữ thường xây dựng pipeline dùng chung cho nhiều ngôn ngữ bằng cách:

- Chuẩn hóa biểu diễn ngữ âm (ví dụ: không gian phoneme chung).
- Huấn luyện mô hình trên tập dữ liệu đa ngôn ngữ.
- Áp dụng transfer learning giữa các ngôn ngữ.

Pipeline điển hình:

Text → Phoneme chuẩn hóa → Multilingual Encoder → Acoustic Model → Audio

3.2.3. Pipeline few-shot và cá nhân hóa giọng nói

Đối với Level 3, pipeline thường tách riêng **speaker encoder** để trích xuất đặc trưng giọng nói từ dữ liệu rất nhỏ.

Pipeline phổ biến:

Text → Text Encoder

Audio mẫu → Speaker Encoder

→ Kết hợp đặc trưng → Acoustic Model → Vocoder → Audio

Cách tiếp cận này giúp giảm đáng kể công sức của người dùng, đồng thời giữ được khả năng cá nhân hóa giọng nói.

3.2.4. Pipeline bổ sung cảm xúc và phong cách giọng nói

Để tăng tính biểu cảm, nhiều nghiên cứu bổ sung các thành phần như:

- Emotion embedding,
- Style token,
- Prosody control.

Pipeline mở rộng:

Text + Emotion/Style → Encoder → Acoustic Model → Expressive Vocoder → Audio

3.3. Tổng hợp định hướng nghiên cứu hiện tại

Các pipeline nghiên cứu hiện nay đều hướng tới việc **kết hợp ưu điểm của nhiều level**, cụ thể:

- Đạt tốc độ và hiệu quả tài nguyên như Level 1,
- Giữ chất lượng tự nhiên như Level 2,
- Đảm bảo tính linh hoạt và cá nhân hóa như Level 3.

Xu hướng chung là xây dựng các **foundation model cho TTS**, có khả năng thích ứng nhanh với người dùng mới, đa ngôn ngữ, và vẫn đảm bảo hiệu suất thực tế.

3.4. Liên hệ vấn đề đạo đức trong pipeline TTS

Bên cạnh yếu tố kỹ thuật, nhiều pipeline nghiên cứu hiện nay đã tích hợp:

- Nhúng watermark vào âm thanh đầu ra,
- Cơ chế truy vết nguồn gốc âm thanh,
- Các biện pháp hạn chế lạm dụng công nghệ TTS cho mục đích giả mạo.

Điều này cho thấy nghiên cứu TTS hiện đại không chỉ tập trung vào hiệu năng mà còn hướng tới **tính an toàn và trách nhiệm xã hội**.

Bảng 3.1. So sánh các hướng tiếp cận và pipeline nghiên cứu trong bài toán TTS

Level	Hướng tiếp cận	Pipeline điển hình	Ưu điểm	Nhược điểm	Trường hợp sử dụng phù hợp
Level 1	Dựa trên luật (Rule-based)	Text → Phân tích ngôn ngữ → Phoneme → Ghép âm → Audio	- Tốc độ xử lý rất nhanh - Tốn ít tài nguyên - Dễ mở rộng đa ngôn ngữ	- Giọng nói thiếu tự nhiên - Ngữ điệu cứng nhắc - Không thể hiện cảm xúc	- Hệ thống đọc thông báo - Thiết bị cấu hình thấp - Ngôn ngữ ít dữ liệu
Level 2	Deep Learning (fine-tuning theo người nói)	Text → Encoder → Acoustic Model → Vocoder → Audio	- Giọng nói tự nhiên - Cá nhân hóa giọng nói - Tài nguyên thấp hơn Level 3	- Cần dữ liệu ghi âm cho từng người - Khó mở rộng đa ngôn ngữ	- Trợ lý ảo cá nhân - Hệ thống đọc sách - Giọng thương hiệu
Level 3	Few-shot / Zero-shot	Text → Text Encoder Audio mẫu →	- Chỉ cần vài giây âm thanh	- Model phức tạp - Tốn nhiều	- AI agent đa nhân vật - Game,

Level	Hướng tiếp cận	Pipeline điển hình	Ưu điểm	Nhược điểm	Trường hợp sử dụng phù hợp
		Speaker Encoder → Fusion → Vocoder → Audio	- Mở rộng cho nhiều người dùng - Tiềm năng đa ngôn ngữ	- tài nguyên - Nguy cơ deepfake	- phim, dubbing - Cá nhân hóa cao

4. Tổng hợp, thảo luận và định hướng nghiên cứu trong bài toán Text To Speech

4.1. Tổng hợp các hướng tiếp cận trong bài toán TTS

Qua quá trình khảo sát, có thể nhận thấy bài toán Text To Speech (TTS) đã phát triển theo ba hướng tiếp cận chính, từ các hệ thống dựa trên luật đơn giản cho đến các mô hình học sâu phức tạp và các phương pháp few-shot hiện đại. Mỗi hướng tiếp cận được thiết kế nhằm giải quyết những yêu cầu khác nhau về hiệu suất, chất lượng giọng nói và khả năng mở rộng.

Các hệ thống dựa trên luật (Level 1) có ưu thế về tốc độ và tài nguyên tính toán, nhưng hạn chế lớn về tính tự nhiên. Ngược lại, các mô hình Deep Learning (Level 2) cải thiện đáng kể chất lượng âm thanh, song phụ thuộc nhiều vào dữ liệu huấn luyện. Các phương pháp few-shot và zero-shot (Level 3) giúp giảm công sức của người dùng và tăng khả năng cá nhân hóa, nhưng lại yêu cầu kiến trúc phức tạp và tài nguyên lớn.

4.2. Đánh đổi giữa hiệu suất, chất lượng và tài nguyên

Một trong những vấn đề cốt lõi của nghiên cứu TTS là **sự đánh đổi** giữa ba yếu tố: tốc độ xử lý, chất lượng giọng nói và tài nguyên tính toán. Các nghiên cứu hiện tại cho thấy không tồn tại một mô hình duy nhất có thể tối ưu đồng thời tất cả các yếu tố này.

Do đó, việc lựa chọn hướng tiếp cận TTS cần dựa trên:

- Mục tiêu sử dụng (thời gian thực, cá nhân hóa, đa ngôn ngữ),
- Khả năng tài nguyên phân cứng,
- Quy mô người dùng và dữ liệu sẵn có.

4.3. Xu hướng nghiên cứu hiện tại

Các xu hướng nghiên cứu nổi bật trong bài toán TTS hiện nay bao gồm:

- Xây dựng các **foundation model** có khả năng thích ứng với nhiều ngôn ngữ và giọng nói.
- Phát triển các mô hình **nhẹ và hiệu quả hơn**, phù hợp với triển khai thực tế.
- Bổ sung khả năng **biểu đạt cảm xúc và phong cách nói** nhằm tăng tính tự nhiên.
- Tích hợp TTS vào các hệ thống **AI/Agent đa phương thức**, kết hợp với thị giác và xử lý ngôn ngữ tự nhiên.

4.4. Vấn đề đạo đức và trách nhiệm trong nghiên cứu TTS

Sự phát triển nhanh chóng của TTS, đặc biệt là các mô hình few-shot, đặt ra nhiều vấn đề về đạo đức và trách nhiệm xã hội. Việc sao chép hoặc giả mạo giọng nói có thể dẫn đến các hành vi lừa đảo, lan truyền thông tin sai lệch và xâm phạm quyền riêng tư.

Do đó, nhiều nghiên cứu hiện nay đã chú trọng tới:

- Nhúng watermark vào âm thanh do AI tạo ra,
- Phát triển các phương pháp phát hiện giọng nói tổng hợp,
- Xây dựng khung pháp lý và chuẩn mực sử dụng công nghệ TTS.

4.5. Kết luận chung

Tổng kết lại, bài toán Text To Speech là một lĩnh vực nghiên cứu năng động, có nhiều hướng tiếp cận khác nhau và vẫn đang tiếp tục phát triển mạnh mẽ. Việc hiểu rõ ưu – nhược điểm của từng hướng tiếp cận, cũng như cách các nghiên cứu xây dựng pipeline để tối ưu hiệu năng, là nền tảng quan trọng cho việc ứng dụng TTS một cách hiệu quả và có trách nhiệm trong thực tế.

5. Kết luận

Bài toán Text To Speech (TTS) là một trong những lĩnh vực quan trọng và phát triển nhanh trong trí tuệ nhân tạo, với nhiều hướng tiếp cận khác nhau nhằm đáp ứng các yêu cầu đa dạng của ứng dụng thực tế. Thông qua việc khảo sát tổng quan tình hình nghiên cứu, bài báo cáo đã trình bày ba hướng tiếp cận chính trong TTS, bao gồm các hệ thống dựa trên luật, các mô hình Deep Learning và các phương pháp few-shot/zero-shot hiện đại.

Mỗi hướng tiếp cận đều có những ưu điểm và hạn chế riêng. Các hệ thống dựa trên luật nổi bật về hiệu suất và chi phí thấp nhưng hạn chế về tính tự nhiên. Các mô hình Deep Learning mang lại chất lượng giọng nói cao hơn song phụ thuộc nhiều vào dữ liệu huấn luyện. Trong khi đó, các phương pháp few-shot cho phép cá nhân hóa giọng nói với ít dữ liệu nhưng đòi hỏi kiến trúc phức tạp và tài nguyên tính toán lớn.

Các nghiên cứu hiện nay tập trung vào việc xây dựng các pipeline nhằm kết hợp ưu điểm của nhiều hướng tiếp cận, hướng tới các hệ thống TTS có khả năng hoạt động nhanh, tiết kiệm tài nguyên, đảm bảo tính tự nhiên, hỗ trợ đa ngôn ngữ và giảm công sức cho người dùng. Đồng thời, các vấn đề đạo đức như nguy cơ giả mạo giọng nói cũng ngày càng được quan tâm, với các giải pháp như nhúng watermark và truy vết nguồn gốc âm thanh.

Nhìn chung, việc hiểu rõ bức tranh tổng thể của bài toán TTS và các hướng nghiên cứu hiện tại không chỉ giúp lựa chọn phương pháp phù hợp cho từng ứng dụng cụ thể, mà còn là nền tảng quan trọng cho việc phát triển và sử dụng công nghệ TTS một cách hiệu quả và có trách nhiệm trong tương lai.